

APLICAÇÃO DE VISÃO COMPUTACIONAL NA DETECÇÃO DE CÂNCER DE MAMA: UTILIZANDO YOLO 11 PARA ANÁLISE DE IMAGENS DE ULTRASSOM

Juan José Gouvêa Cardenas

Felipe Ramirez Pereira Botero

Orientador: Jean Marques Lobo

RESUMO

O câncer de mama no Brasil cresce cerca de 2% ao ano, segundo dados do INCA, de 2018. Essa taxa é preocupante no âmbito da saúde, visto que enfrentamos uma crise de profissionais de saúde no país, assim como de equipamentos de imagem na esfera pública. Diante desse cenário, surge a necessidade do uso do avanço tecnológico para quebrar a fronteira da escassez de recursos humanos e de equipamentos. Como o câncer é identificado principalmente através de exames de imagens, abre a oportunidade do uso da visão computacional para auxiliar no diagnóstico precoce, assim, um modelo como YOLO (You Only Look Once), que trabalha com uma rede neural convolucional, e tem grande destaque na detecção de objetos, pode oferecer precisão e eficiência no diagnóstico. O modelo pode ser treinado utilizando o conceito de KT (Knowledge Transfer), passando um dataset com radiografias, mamografias e outros exames de imagens, permitindo, dessa forma, identificar padrões e características suspeitas de câncer, que possam indicar a presença de calcificações, lesões e massas, por exemplo.

Palavras-chave: Visão Computacional. Redes neurais. Detecção precoce de Câncer. Processamento de imagens.

1. INTRODUÇÃO

Segundo o Instituto Nacional do Câncer (INCA), entre os tipos de câncer com maior prevalência no Brasil, se destaca o câncer de mama feminino, ficando em segundo lugar abaixo do câncer de pele. Em 2024, foram estimados 73 mil novos casos, com riscos de 66,54 casos a cada 100 mil mulheres.” (INCA, 2024)

O diagnóstico precoce é uma parte crucial para que o tratamento do câncer seja eficaz, chegando a uma taxa de cura de aproximadamente 90%. No entanto, o sistema de saúde público brasileiro enfrenta desafios com a falta de equipamentos de mamografia, que, em 2023, contava com aproximadamente 6.588 unidades, representando uma proporção de apenas 6,06 equipamentos para cada 100 mil mulheres. Além disso, há uma escassez de médicos radiologistas, com uma média de 5,5 profissionais por 100 mil habitantes. Essa realidade indica uma lacuna significativa no atendimento, dificultando o acesso ao diagnóstico precoce e aumentando a mortalidade associada ao câncer de mama. (INCA, 2023)

Atualmente, a visão computacional é um grande e promissor braço da inteligência artificial, onde existem milhões de projetos para automação, seja industrial, residencial, entre outros. Assim, surge modelos que permitem encurtar o processo de desenvolvimento de modelos de detecção de objetos, como é o caso do YOLO (You Only Look Once), um modelo que utiliza Rede neural Convolucional (CNN), e que permite uma personalização através de um treinamento supervisionado, assim, qualquer pessoa que possua noção básica de linguagem de programação em Python pode manipulá-lo de forma a desenvolver uma ferramenta nova a partir de um conjunto de parâmetros pré-definidos pelo desenvolvedor.

Com um modelo pré-treinado, é possível utilizar parte do conhecimento acumulado para atender e encurtar o processo de criação de novas ferramentas utilizando a transferência de conhecimento chamada de KT - Knowledge Transfer, que se resume em uma estratégia de reaproveitamento de uma base matemática para um novo projeto, como a criação de sistemas de identificação de neoplasias através de exames de imagens, como a mamografia, por exemplo. (Zhuang et al., 2021).

2. REFERENCIAL TEÓRICO

Com grande crescimento e envelhecimento da população, bem como a influência da alimentação como fatores de risco ambientais na incidência do câncer, surge o desafio de como realizar o diagnóstico em tempo hábil, desafiando a tecnologia a solucionar tal problemática. Impulsionando áreas como a visão computacional, que permite que máquinas possam interpretar imagens e vídeos em tempo real, esse sistema tem um papel importante na automação de processos em diversos segmentos. Assim, existem diversos modelos como

ResNet, desenvolvido pela *Microsoft*, *Tensor Flow*, desenvolvido pelo *Google*, *VGG*, desenvolvido pela *Oxford* e *YOLO*, sendo este último um modelo de detecção de objetos em tempo real, largamente utilizado em projetos nas áreas de automação, segurança e até na medicina. (Voulodimos, 2018)

Essa relação entre a visão computacional e a internet das coisas tem gerado grandes avanços na criação de ferramentas e novas áreas de pesquisa, uma vez que promove não só o desenvolvimento dos serviços urbanos como também a melhor gestão dos recursos envolvidos. E como fruto desse relacionamento é possível demonstrar seu uso na busca e detecção de câncer de forma precoce, podendo transformar o tratamento mais eficaz, contribuindo para a redução da mortalidade, bem como o custo de triagem que seria reduzido. (Kachaamy, 2023)

2.1. VISÃO COMPUTACIONAL

A visão computacional é uma área de destaque atualmente, visto que é a forma que a ciência da computação permite que computadores possam compreender o ambiente a sua volta através de informações coletadas em fotografias e vídeos. Utilizando de cálculos matemáticos, é possível processar as imagens de forma matricial e reconhecer objetos, pessoas, e até cenários.

Em 1989 LeCunn (1989) propôs uma arquitetura de rede baseada em camadas convolucionais e camadas totalmente conectadas. Tal rede foi treinada por meio do algoritmo de backpropagation, sendo aplicada também para o reconhecimento de dígitos manuscritos atingindo um erro de classificação de 5%, usando 2 camadas convolucionais e 2 totalmente conectadas.

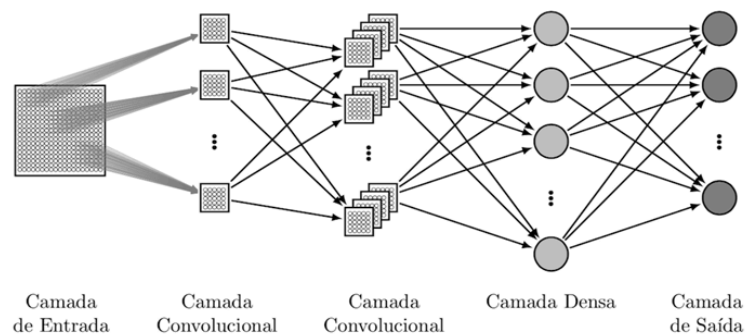
Para aumentar a precisão desses algoritmos e técnicas, é comum utilizar redes neurais convolucionais. Entre diversas abordagens, neste projeto será abordado um modelo de detecção em tempo real, YOLO, aumentando significativamente a velocidade e precisão na detecção e reconhecimento de objetos através de seu algoritmo.

2.2. REDES NEURAIIS CONVOLUCIONAIS (CNNs)

Segundo Pacheco (2016), a CNN assume que todas as entradas são imagens, o que permite codificar algumas propriedades na arquitetura, destacando assim a importância das redes neurais convolucionais no processamento de dados visuais (p. 01).

Assim, as CNN são a chave para o sistema de detecção de objetos, fornecendo a base para análise de imagens. São redes que trazem a ideia de camadas, que coletam informações visuais, seguida por camada de pooling e classificação, auxiliando e determinando a presença de objetos específicos. Pode ser visto como são as camadas da rede neural abaixo:

Figura 2: Diagrama de uma Rede Neural Convolucional.



Fonte: Adaptado de Sakurai, 2020

Em um sistema de detecção de câncer, a aplicação de uma CNN permite a detecção automática de características de nódulos e massas, combinado com a técnica de visão computacional, o modelo Yolo, para criação de uma solução de monitoramento em tempo real, de forma a contribuir com o diagnóstico preventivo.

2.3. MODELO YOLO PARA DETECÇÃO EM TEMPO REAL

O YOLO é um dos modelos de deep learning mais populares para detecção de objetos em tempo real. Outro algoritmo que tem sido amplamente utilizado é o *Faster R-CNN* (Region- based Convolutional Neural Network), que é conhecido por sua precisão, mas é mais lento em comparação com o YOLO e o SSD. O Faster R-CNN usa uma rede neural convolucional para extrair recursos da imagem e, em seguida, propõe regiões de interesse onde objetos podem estar presentes. Em seguida, uma caixa delimitadora é gerada em torno de cada região proposta para identificar os objetos, segundo Taigman (2014).

Assim sua precisão e eficiência o fazem uma ótima escolha para o projeto de detecção e rastreamento de câncer. Entre os aspectos mais relevantes do YOLO, podemos citar:

- **Detecção Unificada:** consiste em dividir a imagem em grade, e cada célula da grade fica responsável por detectar objetos que possam cair dentro dessa célula.
- **Velocidade:** o YOLO é capaz de processar uma imagem inteira em uma única passagem, o que resulta em uma velocidade muito alta, sendo perfeito para aplicações em tempo real.
- **Precisão:** apesar de sua velocidade, o YOLO possui uma grande precisão em comparação com outros modelos.
- **Robustez:** o modelo pode trabalhar com condições variadas de iluminação e ângulos, o que é muito importante para o projeto.

- Escalabilidade: o modelo pode trabalhar com os mais variados tamanhos de imagem, pois com a sua precisão e velocidade pode se adaptar a diferentes cenários, como volume de imagens e análises.

Assim podemos citar o caso da “MIA”, uma ferramenta de inteligência artificial testada pelo NHS, o serviço público de saúde do Reino Unido, identificou com sucesso pequenos sinais de câncer de mama que não foram diagnosticados por especialistas.


O modelo, devido à sua alta velocidade e precisão, oferece vantagens consideráveis sobre outros métodos de detecção, como o Faster R-CNN, que, embora preciso, é mais lento e menos adequado para diagnósticos em tempo real. A capacidade de YOLO de ser treinado com imagens específicas de mamografia permite detectar padrões de câncer de mama com precisão, ajudando os radiologistas a focarem nas áreas de maior interesse. Em regiões carentes de especialistas, o uso de YOLO poderia reduzir o tempo de diagnóstico e aumentar a acessibilidade ao atendimento.

2.4. Estudo de Caso: MIA no NHS

Em um caso da aplicação da visão computacional no ambiente médico, podemos citar o caso da “MIA” (Mammography Intelligence Assessment), que é uma ferramenta de inteligência artificial, testada pelo NHS, o serviço público de saúde do Reino Unido.

A ferramenta analisou mamografias de mais de 10 mil mulheres, onde na maioria dos casos não identificou câncer, mas conseguiu sinalizar com sucesso todos aqueles que os médicos já haviam identificado, além de diagnosticar 11 casos que os médicos não perceberam os tumores, segundo a Kheiron Medical Technologies, que desenvolveu a *MIA* em parceria com a Microsoft. Assim pode se ver como está o cenário do Brasil de óbitos por câncer:

Figura 1: Número de óbitos por faixa etária.



Fonte: Uname, 2022

2.5. APLICAÇÕES PRÁTICAS

Os modelos de inteligência artificial (IA) têm demonstrado eficácia na detecção de doenças em exames radiológicos, onde podem reconhecer padrões e características que o olho humano pode não perceber. Essa aplicação aumenta a precisão de diagnóstico e reduz o tempo necessário para revisão de exames, permitindo o início do tratamento em menos tempo. Nesse contexto, Lombelo et al. (ano) destacam que "o tempo médio para diagnóstico foi de 70 dias, sendo menor para aquelas que descobriram a doença por exames de rastreamento e diagnosticadas em estádios iniciais.". Essa agilidade no diagnóstico e no tratamento é crucial para melhorar os desfechos clínicos e a qualidade de vida dos pacientes.

Outra aplicação é o uso de algoritmos para monitoramento de condições crônicas, que através de dispositivos conectados, é possível que monitores de glicose, sensores cardíacos, possam ser analisados em tempo real alertando médico e paciente sobre potenciais crises antes de ocorrerem. Essa capacidade de monitoramento contínuo contribui para o tratamento preventivo e melhora a qualidade de vida dos pacientes, reduzindo internações e intervenções de emergência.

3. MATERIAIS E MÉTODOS

Nesta seção, apresentamos os materiais e métodos utilizados para a implementação do projeto de inteligência artificial (IA) voltado para a detecção de doenças em exames radiológicos. Os materiais incluem os dados, ferramentas e tecnologias que sustentam a pesquisa, enquanto os métodos abrangem os procedimentos adotados para o pré-processamento, desenvolvimento, avaliação e implementação do modelo. Essa abordagem visa garantir que o sistema proposto seja eficaz, confiável e aplicável no contexto clínico.

3.1 DADOS

Utilizaremos imagens obtidas através de repositório público disponível no kaggle *Breast Ultrasound Images Dataset*, o qual permite que outros usuários possam utilizar esse dataset para treinamento de modelos. Esses dados foram coletados em sua maior parte em hospitais privados norte-americanos, banco de dados públicos, sendo em sua grande parte mamografia, sendo esse um exame recorrente no cuidado feminino, com uma massa de dados aproximada de 1578 imagens, mas por amostragem utilizaremos apenas 780 imagens.

3.2. FERRAMENTAS E TECNOLOGIAS

Foi utilizado como meio facilitador o Kaggle, sendo uma plataforma para ciência de dados e inteligência artificial, utilizando python como linguagem padrão no desenvolvimento do modelo, onde faremos uso das bibliotecas Pandas, Numpy e Matplotlib, as quais serão necessárias para construção de nosso algoritmo de treinamento, onde utilizaremos para

processamento de dados, cálculos matemáticos e construção de gráficos respectivamente, entre outras.

3.3. DESENVOLVIMENTO DO MODELO

No desenvolvimento deste modelo para detecção de câncer de mama, utilizamos a rede YOLO (You Only Look Once), na versão YOLO 11, configurada para detectar anomalias em imagens de ultrassom, ajudando no diagnóstico precoce de câncer de mama. A variante *YOLO11m.pt* foi empregada em um conjunto de dados de 780 imagens, que passou por um extenso processo de pré-processamento e rotulação, resultando em 647 labels. Esta divisão permitiu a criação de um dataset robusto, separado em 80% para treinamento e 20% para validação, possibilitando uma análise equilibrada da performance do modelo.

Os passos para a construção do modelo foram organizados da seguinte maneira.

1. **Instalação e Configuração:** Inicialmente, instalamos os pacotes necessários, como *ultralytics*, *opencv-python*, *pyyaml*, *tqdm*, e *ipywidgets* para lidar com o YOLO e auxiliar no pré-processamento de imagens.
2. **Estruturação do Dataset:**
 - Criamos uma estrutura de diretórios base para armazenar imagens e labels, visando uma organização clara dos dados de treino e validação.
 - Verificamos a disponibilidade do dataset e, em seguida, construímos listas de imagens e suas respectivas máscaras para as classes "benigno", "maligno" e "normal".
3. **Criação de Labels:** Para cada imagem rotulada, calculamos as coordenadas de bounding boxes normalizadas para o modelo YOLO. Este processo envolveu a leitura de cada imagem e máscara, a determinação das áreas de interesse (lesões) e a criação de arquivos de labels no formato YOLO, com valores de *x_center*, *y_center*, *width* e *height*.
4. **Organização do Dataset:** As imagens foram distribuídas em pastas específicas para treino e validação. O uso do *train_test_split* garantiu uma separação aleatória e consistente entre ambos os subconjuntos de dados.
5. **Treinamento do Modelo:** Criamos um arquivo *YAML* de configuração, contendo detalhes do dataset e as classes "benigno" e "maligno". Este arquivo foi essencial para configurar o treinamento, que ocorreu em 50 épocas, permitindo uma evolução gradual da precisão do modelo.

6. Avaliação e Visualização:


- Implementamos funções para avaliar o modelo em imagens de teste, onde foram gerados bounding boxes e visualizações para detecção de massas benignas, malignas e normais.
- A avaliação envolveu a criação de gráficos de distribuição de confiança e matrizes de confusão, que permitiram uma análise detalhada do desempenho do modelo, incluindo métricas de precisão, revocação e f1-score.

Visualização dos Resultados: Utilizando histogramas e heatmaps, analisamos a confiança nas predições e a distribuição das classes, proporcionando insights detalhados sobre a eficácia do modelo e seus pontos de melhoria.

3.4. AVALIAÇÃO DO MODELO

A avaliação do modelo se deu através da comparação de sua assertividade com as imagens de seu dataset, assim podemos identificar o nível de precisão, recall e F 1, como podemos ver abaixo:


Gráfico 1: Métricas de desempenho do modelo de detecção de câncer de mama



Fonte: Autoria própria. Matplotlib

Assim fazendo uso da matriz de confusão podemos verificar a performance do modelo na detecção das diferentes classes, conforme gráfico abaixo:

Gráfico 2: Matriz confusão




Fonte: Autoria própria. Matplotlib

Observamos que o modelo apresentou excelente desempenho na detecção de lesões *benignas* e *malignas*. No entanto, houve uma taxa de falsos positivos maior na classificação de imagens normais, indicando que o modelo, em alguns casos, identifica estruturas normais como possíveis lesões. Isso pode ser atribuído ao menor número de exemplos da classe *Normal* no dataset, sugerindo a necessidade de equilibrar melhor as classes em futuros trabalhos.

A distribuição da confiança nas predições demonstra que a maioria das detecções foi realizada com alta confiança, especialmente no intervalo acima de 0.9, conforme ilustrado no histograma abaixo:

Gráfico 3: Distribuição de confiança nas predições




Fonte: Autoria própria. Matplotlib

Essa alta confiança nas predições é fundamental em aplicações médicas, pois reduz a probabilidade de falsos negativos, que são críticos no contexto do câncer de mama.


Algumas imagens sobre a identificação e classificação realizada pelo modelo, assim como o grau de confiança:

Figura 3: Ultrassons com detecção de 45% maligno e a segunda com 94% benigno



Fonte: Autoria própria. YOLO

Figura 4: Imagem de ultrassonografia sem presença de câncer identificada



Fonte: Autoria própria. YOLO

Essas representações visuais evidenciam a capacidade do modelo em identificar e delimitar regiões suspeitas nas imagens de ultrassom, fornecendo um suporte significativo para profissionais de saúde na análise diagnóstica.

4. CONSIDERAÇÕES FINAIS

A aplicação do modelo YOLO para detecção de câncer de mama em imagens de ultrassom demonstrou resultados expressivos, destacando-se pela elevada precisão e recall, particularmente nas classes de maior relevância clínica. A arquitetura robusta do YOLO,

aliada a técnicas avançadas de pré-processamento, contribuiu para sua capacidade de generalização, fazendo deste modelo uma ferramenta promissora para o diagnóstico assistido por computador. Assim, este projeto não apenas contribui para a literatura ao evidenciar o potencial da visão computacional no auxílio ao diagnóstico precoce do câncer de mama, como também oferece uma alternativa acessível e eficaz que pode beneficiar áreas com escassez de recursos e especialistas. A detecção automatizada pelo YOLO mostra-se, assim, uma abordagem viável para integrar-se a sistemas médicos, promovendo a ampliação do alcance diagnóstico e melhorando a eficácia dos tratamentos em locais onde o acesso a profissionais especializados é limitado.

Apesar dos resultados promissores, o modelo ainda necessita de uma validação mais rigorosa para minimizar a ocorrência de falsos positivos, garantindo que os resultados sejam interpretados com precisão e segurança. Dessa forma, o YOLO pode complementar o trabalho dos radiologistas, auxiliando no diagnóstico precoce e melhorando os desfechos de tratamento, mas sem substituir o papel essencial da avaliação profissional na interpretação dos exames.

5. REFERÊNCIAS

AL-DHABYANI, W., et al. Dataset of breast ultrasound images. *Data Brief*, v. 28, 2019.

DOI: <<https://doi.org/10.1016/j.dib.2019.104863>> Acesso em: 2 nov. 2024.

GHIDA, J. L., et al. Strategies to Prevent or Remediate Cancer and Treatment-Related Aging, 2020.

INCA - Instituto Nacional de Câncer. Controle do câncer de mama. Disponível em:

<<https://www.gov.br/inca/pt-br/assuntos/gestor-e-profissional-de-saude/controle-do-cancer-de-mama>> Acesso em: 2 nov. 2024.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). Censo 2022:

Panorama. Disponível em: <<https://censo2022.ibge.gov.br/panorama>> Acesso em: 2 nov. 2024.

KACHAAMY, T. Artificial intelligence and machine learning in cancer detection. *Targeted Oncology*, 3 de maio de 2023. Disponível em:

<<https://www.targetedonc.com/view/artificial-intelligence-and-machine-learning-in-cancer-detection>> Acesso em: 2 nov. 2024.

LECUN, Y., et al. Backpropagation Applied to Handwritten Zip Code Recognition. *Neural Comput.*, MIT Press, Cambridge, MA, USA, v. 1, n. 4, p. 541–551, 1989. DOI:

<<http://dx.doi.org/10.1162/neco.1989.1.4.541>> Acesso em: 2 nov. 2024.

LOMBELO, Angélica Atala, et al. Time to diagnosis and treatment for breast cancer in public and private health services. *Revista Gaúcha de Enfermagem*, v. 43, 2022.

MINISTÉRIO DA SAÚDE. Outubro Rosa: Ministério da Saúde lança campanha e reforça autocuidado. Disponível em:

<<https://www.gov.br/saude/pt-br/assuntos/noticias/2024/outubro/outubro-rosa-ministerio-da-saude-lanca-campanha-e-reforca-autocuidado>> Acesso em: 2 nov. 2024.

OBSERVATÓRIO DA SAÚDE PÚBLICA. Câncer de mama. Disponível em:

<<https://observatoriosaudepublica.com.br/tema/cancer-de-mama>> Acesso em: 2 nov. 2024.

PACHECO, André G. C. Classificação de espécies de peixe utilizando redes neurais convolucionais. Vitória - ES: Universidade Federal do Espírito Santo, 2016.

PYTHON SOFTWARE FOUNDATION. The Python Standard Library. Disponível em:

<<https://docs.python.org/3/>> Acesso em: 2 nov. 2024.

ROCHE PLUS. Una nueva IA detecta un 13% más casos de cáncer de mama. Disponível em:

<<https://www.rocheplus.es/innovacion/inteligencia-artificial/mia-para-cancer-mama.html>>

Acesso em: 2 nov. 2024.

SAKURAI, L. M. CNN e MapReduce. Disponível em:

<<https://www.sakurai.dev.br/cnn-mapreduce>.> Acesso em: 2 nov. 2024.

TAIGMAN, Yaniv; MING, Yang; RANZATO, Marc Aurelio; WOLF, Lior. DeepFace:

Closing the Gap to Human-Level Performance in Face Verification, 2014. Disponível em:

<<https://ieeexplore.ieee.org/document/6909616>.> Acesso em: 2 nov. 2024.

ULTRALYTICS. Documentação Ultralytics YOLO. Disponível em:

<<https://docs.ultralytics.com/pt>.> Acesso em: 2 nov. 2024.

VOULODIMOS, A., et al. Deep learning for computer vision: A brief review.

Computational Intelligence and Neuroscience, 2018.

ZHUANG, F., et al. A Comprehensive Survey on Transfer Learning. *IEEE Transactions on Knowledge and Data Engineering*, v. 22, n. 2, 2021.